

基于 GRPO 与思维链蒸馏的小型大语言模型数学推理能力增强

邹研泽, 3024244444

摘要

本实验选题为课程设计要求中的自选课题, 研究方向属于深度学习与大语言模型后训练领域, 聚焦大语言模型数学推理增强这一前沿问题。针对大语言模型在数学文字题任务中存在推理能力有限、答案格式不稳定以及后训练方法作用机制不清晰等问题, 本文以 GSM8K 小学数学应用题为主要评测任务, 围绕 Qwen2.5-1.5B-Instruct 构建了包含 Base 评测、思维链监督微调 (CoT-SFT)、GRPO 强化学习后训练、复合奖励消融与输出行为诊断的实验流程。方法上, 本文首先采用 GSM8K 风格的开源蒸馏数据进行 CoT-SFT, 使模型学习分步骤求解和 Final Answer 规范输出; 随后使用 GRPO 在 GSM8K 训练集上进行基于规则奖励的强化学习, 并比较仅正确性奖励、正确性与格式复合奖励、以及正确性、格式和长度惩罚联合奖励的效果。实验结果表明, 原始模型在完整 GSM8K 测试集上的严格准确率为 42.38%, 格式成功率为 53.22%; CoT-SFT 将严格准确率提升至 63.08%, 并将格式成功率提高到 99.17%; 单独 GRPO 获得最高严格准确率 69.98%, 但同时带来平均输出长度上升和过度推理率增加; SFT-GRPO 系列在格式稳定性方面表现更优, 其中加入长度惩罚的 R3 组达到 64.75% 严格准确率。进一步分析发现, 所有实验组的输出长度与正确率相关系数均为负值, 说明更长的推理文本并不必然代表更强的推理能力。实验表明, 小模型数学推理增强不能只关注最终准确率, 还应结合格式规范性、答案抽取可靠性、输出长度和错误类型等行为指标进行综合分析。

关键词— LLM; GRPO; 思维链蒸馏; 强化学习后训练; GSM8K; 数学推理

1. 引言

近年来, 大语言模型在自然语言理解、代码生成和数学推理等任务中取得了显著进展。与传统分类或回归模型不同, 大语言模型的数学推理能力不仅依赖最终答案, 还依赖中间步骤的组织、条件理解、数值计算和答案格式控制。尤其是在数学文字题中, 模型需要从自然语言描述中抽取数量关系, 建立计算链条, 并在最后给出可被自动评测系统解析的结果。因此, 数学推理任务既是衡量语言模型推理能力的重要基准, 也是观察模型后训练行为变化的典型场景。

思维链 (Chain-of-Thought, CoT) 方法的出现推动了语言模型推理研究的发展^[1]。相关研究表明, 让模型显式生成中间推理步骤能够改善复杂推理任务的表现, 尤其是在算术推理、常识推理和符号推理中具有明显效果。CoT 的核心思想并不是直接要求模型输出答案, 而是引导模型先进行分步骤分析, 再给出最终结果。对于小型模型而言, CoT 能否通过监督微调被稳定学习, 是一个值得研究的问题。因为小模型的参数容量有限, 过长或过复杂的思维链可能带来风格迁移, 却不一定带来真正的推理能力提升。

与此同时, 强化学习后训练也成为提升推理模型能力的重要方向。DeepSeek-R1 和 DeepSeekMath 等工作显示, 在数学任务中使用基于规则的正确性奖励和格式奖励, 可以在不依赖人工偏好模型的情况下推动模型

形成更强的推理行为^[5,6]。此外，Qwen2.5-Math 等开源数学模型也表明，面向数学任务的持续训练、自我改进和后训练策略能够显著提升模型的数学推理能力^[8]。与传统 PPO 相比^[4]，GRPO 通过组内相对奖励估计优势，减少了显式价值模型的需求^[9]，降低了强化学习后训练的显存和实现复杂度。该思路非常适合课程设计场景中对小模型进行可复现实验：模型规模不需要很大，奖励函数可以由答案抽取和格式匹配自动构造，实验过程也便于诊断。

然而，直接将大规模推理模型的训练范式照搬到小模型上并不一定可靠。首先，SFT 数据的题目分布和答案格式必须与评测任务一致。如果使用竞赛数学或表达式答案作为蒸馏语料，而最终评测任务是 GSM8K 这类小学数学应用题，则可能出现难度错配和答案抽取失败。其次，强化学习奖励若只关注答案正确性，可能诱导模型生成更长的推理过程，甚至出现过度推理。再次，准确率提升本身并不足以解释模型行为，还需要结合格式成功率、答案抽取率、输出长度、过度推理率以及错误案例进行综合分析。

基于上述问题，本文选择“基于 GRPO 与思维链蒸馏的小型大语言模型数学推理能力增强研究”作为课程设计题目。受限于单卡算力、训练时间和实验预算，本文选用参数量较小的 Qwen2.5-1.5B-Instruct 作为主实验基座模型，使用 GSM8K 作为最终测试任务，构建 Base、CoT-SFT、GRPO、SFT-GRPO-R1、SFT-GRPO-R2 和 SFT-GRPO-R3 六组对比实验。本文不仅关注最终准确率，还系统分析模型是否按指定格式输出、是否容易被自动答案抽取器识别、是否存在输出变长和过度推理等现象。

在本节的最后一段中，本文对主要贡献总结如下：

- 1) 构建了一套面向小型大语言模型数学推理增强的完整实验工程，覆盖数据准备、CoT-SFT、GRPO 后训练、LoRA 参数高效微调、答案抽取、指标统计和结果可视化。
- 2) 在完整 GSM8K 测试集上比较了 Base、CoT-SFT、GRPO 以及三种 SFT-GRPO 奖励函数消融方案，证明 CoT-SFT 主要提升格式规范性和严格评测准确

率，而 GRPO 单独训练取得最高准确率但带来更长输出。

- 3) 将输出长度、格式成功率、答案抽取率和过度推理率纳入分析，指出“更长推理不等于更强推理”，并通过实验结果讨论了奖励设计、数据分布和小模型容量之间的关系。

2. 研究方法

2.1 GRPO 与 SFT 方法原理

在展开具体实现之前，本节先对本实验涉及的两类核心后训练方法——强化学习方法 GRPO 与监督微调方法 SFT——的基本原理做简要梳理，总结本人对这两类方法的学习体会，作为后续实现与结果分析的基础。

2.1.1 GRPO

GRPO (Group Relative Policy Optimization, 组相对策略优化) 是一种面向大语言模型的强化学习后训练方法。其机制可从策略梯度的角度理解：策略梯度以奖励为权重放大或抑制某条生成轨迹的概率，但原始奖励方差较大，直接使用会使训练不稳定，因此通常需要一个基线 (baseline) 做“相对好坏”的比较以降低方差。传统 PPO 使用一个与策略同规模的价值网络估计该基线，而 GRPO 的关键改进在于：对同一道题采样一组 (G 个) 回答，直接以该组奖励的均值作为基线、以标准差做归一化，从而得到每个回答的组内相对优势 A_i ；在此基础上沿用 PPO 的裁剪式替代目标限制单步更新幅度，并对参考模型施加 KL 惩罚以防策略偏离过远：

$$A_i = \frac{r_i - \text{mean}(r_1, \dots, r_G)}{\text{std}(r_1, \dots, r_G) + \varepsilon}$$

$$J(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_i \min(\rho_i A_i, \text{clip}(\rho_i, 1 - \varepsilon, 1 + \varepsilon) A_i) - \beta \text{KL}(\pi_\theta \| \pi_{\text{ref}}) \right]$$

$$\rho_i = \frac{\pi_\theta(y_i|x)}{\pi_{\theta_{\text{old}}}(y_i|x)}$$

本人对该方法的体会是，GRPO 的“相对 (Relative)”二字是关键：它并不追求绝对的奖励高低，而是不断让模型在同一道题的一组尝试中向更好的回答靠拢。这样既省去了价值网络的显存开销，又避免了人工偏好标注，非常契合本实验的设计场景。

2.1.2 SFT

SFT (Supervised Fine-Tuning, 监督微调) 是后训练中最基础的方法, 本质上是一种模仿学习。给定题目 x 与带有推理过程和最终答案的目标文本 y , SFT 以标准自回归语言建模损失训练模型, 使其逐 token 拟合目标序列:

$$\mathcal{L}_{SFT}(\theta) = - \sum_{t=1}^{|y|} \log \pi_{\theta}(y_t | x, y_{<t})$$

训练时采用 teacher forcing, 模型在每一步都以真实前文 token 为条件预测下一个 token, 因此它学到的并非“如何推理”本身, 而是“如何复现教师示范的推理轨迹”。本实验所用的思维链蒸馏, 蒸的正是大模型解题时展开的中间步骤——把这种逐步求解的书写范式迁移到小模型上。

需要说明的是, SFT 存在固有局限: 模型至多逼近教师数据的分布, 难以产生训练集中从未出现的新解法; 并且训练阶段以真实前文为条件、推理阶段却以自身生成的前文为条件, 存在暴露偏差。正因如此, 本实

验在 SFT 之后进一步引入以最终结果为奖励信号的 GRPO, 以期突破单纯模仿的能力上限。

2.2 任务定义与总体思路

本文研究的问题可以形式化为: 给定一个数学文字题 x , 模型需要生成一段包含中间步骤的回答 y , 并在最后以固定格式输出“Final Answer: a”, 其中 a 是可被自动评测程序解析的单个数值答案。与普通文本生成不同, 本任务对回答有两个同时要求: 一是推理链条应能够得到正确答案, 二是最终答案必须具有稳定的格式。前者对应数学推理能力, 后者对应自动评测和强化学习奖励的可靠性。

实验总体流程包括四个阶段。第一阶段直接评测原始 Qwen2.5-1.5B-Instruct, 得到 Base 能力边界; 第二阶段用 GSM8K 风格的 CoT 蒸馏数据进行 LoRA SFT, 使模型学习分步骤推理和 Final Answer 格式; 第三阶段从原始模型直接进行 GRPO, 观察无 SFT 初始化条件下规则奖励对推理能力的影响; 第四阶段以 SFT 模型为初始化, 再进行不同奖励函数的 GRPO 消融实验, 分析正确性奖励、格式奖励和长度惩罚的作用。




图 1 研究方法总览：(a) 总体实验流程与六组实验（E1 – E5，其中 E4 含两个子组）；(b) 数据构造与答案抽取（strict / lenient 双模式）；(c) GRPO 组内相对优势机制。

2.3 基座模型与参数高效微调

本文选择 Qwen2.5-1.5B-Instruct 作为主实验模型^[7]。该模型规模较小，便于在单张 A800 80GB GPU 上进行多组微调与强化学习实验；同时它已经具备基础指令跟随和一定数学推理能力，适合作为课程设计中研究后训练方法的基座模型。调试阶段使用 Qwen2.5-0.5B-Instruct 进行链路验证，正式结果全部基于 1.5B 模型。

为了降低训练成本，本文所有 SFT 和 GRPO 实验均采用 LoRA 方式进行参数高效微调^[3]，具体实现基于 Hugging Face PEFT 框架^[10]。LoRA 的基本思想是冻结原始权重矩阵 W ，只学习一个低秩增量 ΔW 。若原始线性层权重为 $W \in \mathbb{R}^{d \times k}$ ，则微调后的等效权重可写为：

$$W' = W + \Delta W = W + BA,$$

$$B \in \mathbb{R}^{d \times r}, A \in \mathbb{R}^{r \times k}, r \ll \min(d, k)$$

其中 r 为 LoRA 秩。本文采用 $r = 16$ 、 $\alpha = 32$ 、 $\text{dropout} = 0.05$ ，并将 LoRA 注入到注意力投影层 q_{proj} 、 k_{proj} 、 v_{proj} 、 o_{proj} 以及前馈网络中的 $gate_{proj}$ 、 up_{proj} 、 $down_{proj}$ 。这样既能覆盖 Transformer 中主要可适配模块，又避免全参数训练带来的显存压力。

为更直观地展示基座模型结构与 LoRA 注入位置，模型整体架构如图 2 所示。LoRA 仅在自注意力与前馈网络的线性投影层上引入低秩增量，原始权重保持冻结，因此可训练参数量大幅降低。




图 2 Qwen2.5-1.5B 解码器结构与 LoRA 参数高效微调示意图

2.4 数据集构造与答案抽取

本文最终使用 GSM8K 作为核心任务数据集。

GSM8K 由小学数学应用题组成，题目通常包含自然语言描述和简单算术关系，最终答案一般为单个数值^[2]。由于答案形式相对统一，模型输出的正确性可以通过数值匹配进行自动判断，因此该数据集非常适合用于构建基于规则的奖励函数。

在 SFT 数据方面，本文没有直接采用通用竞赛数学 CoT 数据作为主训练集，而是使用 GSM8K 风格的蒸馏数据。实验早期发现，若使用 OpenR1-Math 这类包含竞赛题、代数表达式、元组答案和选择题答案的数据集^[13]，会与 GSM8K 的题目分布和答案格式产生明显错配。模型可能学习到不适合 GSM8K 任务的推理风格和答案表达方式，从而影响后续强化学习训练和自动评测的稳定性。为避免这一问题，最终数据准备脚本默认使用 camel-ai/gsm8k_distilled 作为 CoT-SFT 数据来源^[12]，并解析其中的 problem、reasoning_solution、groud_truth_solution 和 boxed_answer_success 字段。数据脚本在解析过程中仅保留 boxed_answer_success 为真的样本，并从标准解答或推理文本中提取最终答案。

本文的数据集构造和实验用途如下：

a. CoT-SFT 数据

CoT-SFT 阶段使用 camel-ai/gsm8k_distilled 数据集。本文从中构造 1500 条训练样本和 300 条验证样本，用于监督微调模型，使其学习 GSM8K 风格的中长链式推理过程。该数据集的主要作用是为后续 GRPO 训练提供更稳定的推理初始化模型。

b. GRPO 训练数据

GRPO 阶段使用 openai/gsm8k train split 中的 800 条样本^[11]。这些样本用于规则奖励强化学习后训练，模型根据答案正确性、格式规范性以及长度约束等奖励信号进行优化，从而进一步提升在 GSM8K 任务上的表现。

c. 最终评测数据

最终评测使用完整的 openai/gsm8k test split，共 1319 条样本^[11]。所有实验方法均在该测试集上进行统一评测，以保证不同模型和不同奖励设置之间的结果具有可比性。

由于 CoT-SFT 数据来自第三方蒸馏数据集，为防止测试集泄露，本实验以 GSM8K 官方 test split 的题目为基准，对所有 SFT 与 GRPO 训练数据按题目文本做了归一化去重过滤（精确匹配与近似匹配并用），剔除与测试集重叠或高度相似的样本，确保训练数据与最终评测集无交叠。

在评测格式上，每条样本都采用统一的 prompt，要求模型逐步求解问题，并最终以“Final Answer: <number>”的形式给出答案。这样的设计既方便模型生成规范化输出，也便于后续通过严格抽取和宽松抽取两种方式自动获得最终答案，从而支持准确率、格式遵循率和答案抽取成功率等多维指标的计算。

2.5 CoT-SFT 思维链监督微调

CoT-SFT 的目标是让小模型学习“分步骤推理 + 规范化答案收束”的输出模式^[1]。给定训练样本 (x, y)，其

中 x 为题目, y 为带有推理过程和最终答案的目标文本, SFT 使用标准自回归语言建模损失:

$$L_{\text{SFT}}(\theta) = - \sum_t \log \pi_\theta(y_t | x, y_{<t})$$

其中 π_θ 表示待训练模型, y_t 为目标回答的第 t 个 token。本文在 SFT 配置中启用 `strip_think` 机制, 只使用 `</think>` 之后更简洁的正式解法作为 CoT 目标, 避免模型学习过长、重复和带有强烈 R1 风格的内部推理文本。该设计来自预实验观察: 如果直接使用完整长 CoT, 模型容易生成冗长回答, 并且在 `max_new_tokens` 限制内到不了 Final Answer, 从而降低格式成功率。正式配置中 `max_seq_length` 设置为 2048, 训练 2 个 epoch, 学习率为 $2.0\text{e-}4$, batch size 为 2, 梯度累积为 8, 并使用 bfl6 和梯度检查点降低显存开销。

表 1 CoT-SFT 主要训练参数

参数	取值
Base model	Qwen/Qwen2.5-1.5B-Instruct
Training data	data/processed/sft_train.jsonl
Validation data	data/processed/sft_val.jsonl
LoRA rank / alpha / dropout	16 / 32 / 0.05
max_seq_length	2048
num_train_epochs	2
learning_rate	$2.0\text{e-}4$
per_device_train_batch_size	2
gradient_accumulation_steps	8
target modules	q,k,v,o projection + gate/up/down projection

2.6 GRPO 强化学习后训练

GRPO (Group Relative Policy Optimization) 是一种面向大语言模型后训练的策略优化方法^[5]。与传统 PPO 使用价值模型估计优势不同^[4], GRPO 对同一个 prompt 采样多个候选回答, 并使用这些候选回答的组内奖励均值和标准差进行相对归一化^[5]。直观地说, 如果某个回答在同一组候选中比其他回答更好, 它就会获得正优势; 如果比组内平均水平差, 则会获得负优势。该

方法减少了价值网络开销, 适合本文这种单卡小规模后训练实验。

设同一题目 x 采样得到 G 个回答 $y_1, \dots, y_G$, 每个回答的规则奖励为 r_i , 则可构造组内相对优势:

$$A_i = \frac{r_i - \text{mean}(r_1, \dots, r_G)}{\text{std}(r_1, \dots, r_G) + \varepsilon}$$

训练时使用类似 PPO 的裁剪目标限制策略更新幅度, 并通过 KL 项约束新策略不要过度偏离参考模型。GRPO 训练基于 TRL 的 GRPOTrainer 实现^[9]。本文每个 prompt 采样 `num_generations`=4 个候选, GRPO 最大训练步数为 200, 学习率为 $5.0\text{e-}6$, `max_prompt_length` 和 `max_completion_length` 均为 512。

2.7 奖励函数设计

本实验设计三种规则奖励函数进行消融实验。整体思路是从最基础的答案正确性出发, 逐步加入格式约束和长度约束, 从而分析不同奖励信号对模型推理能力和输出行为的影响。三种奖励函数均基于自动答案抽取实现, 不依赖人工偏好标注, 与 RLVR 思路一致^[5,6]。

2.7.1 R1: 正确性奖励

R1 只关注最终答案是否正确, 是本文最基础的奖励函数。系统首先使用严格模式从模型输出中抽取 Final Answer 后的数值答案。若严格模式无法抽取最终答案, 则说明模型没有遵循规定格式, 给予 -0.5; 若能够抽取且答案正确, 则给予 1.0; 若能够抽取但答案错误, 则给予 0。因此, R1 可写为:

$$R_1 = R_{\text{correct}}$$

R1 的作用是直接优化数学题最终答案的正确性。它的优点是目标明确, 能够检验 GRPO 是否可以仅依靠最终答案奖励提升推理能力; 缺点是只看结果, 不额外鼓励清晰的输出格式和稳定的推理结构。

2.7.2 R2: 正确性 + 格式奖励

在 R1 的基础上, 本文进一步设计 R2, 引入格式奖励 `Rformat`。该奖励主要考察三个方面: 模型输出是否包含 Final Answer 标记, 是否具有分步骤推理痕迹, 以及严格答案抽取是否成功。格式奖励最高为 1, 用于引导模型不仅要算对, 还要按照规定格式给出可解析的最终答案。R2 可写为:

$$R_2 = R_{\text{correct}} + \alpha R_{\text{format}}$$

实验中 $\alpha = 0.2$ 。R2 的改进点在于，它针对 Base 模型常见的“答案可能正确但格式不规范”问题进行约束，使模型输出更适合自动评测和后续奖励计算。

2.7.3 R3: 正确性 + 格式奖励 - 长度惩罚

在 R2 的基础上，本文进一步加入长度惩罚，得到 R3。设计 R3 的原因是：模型在思维链训练或强化学习后可能倾向于生成更长的推理文本，但更长的推理并不一定意味着更高的正确率，反而可能导致冗余推理或过度推理。因此，R3 在保证正确性和格式规范的同时，对过长输出进行惩罚。R3 可写为：

$$R_3 = R_{\text{correct}} + \alpha R_{\text{format}} - \beta R_{\text{length}}$$

实验中 $\alpha = 0.2$ ， $\beta = 0.1$ ，长度无惩罚阈值为 256 words。当输出长度不超过阈值时不惩罚；超过阈值时，根据超出长度进行归一化惩罚。R3 的目标是分析长度约束是否能够减少冗余推理，使模型输出更加简洁稳定。

2.7.4 消融实验设置

基于上述三种奖励函数，本文设置了四组 GRPO 相关实验，用于比较不同初始化方式和不同奖励约束对模型数学推理能力的影响：

a. GRPO 组

该组直接以 Base 模型作为初始化模型，奖励函数使用 R1，即仅根据答案正确性进行奖励。该实验用于观察模型在未经过 SFT 初始化的情况下，直接进行强化学习训练的效果。

b. SFT-GRPO-R1 组

该组以 CoT-SFT merged 模型作为初始化模型，奖励函数同样使用 R1。该实验用于分析在 SFT 初始化之后，仅使用正确性奖励进行 GRPO 训练的效果，从而与未经过 SFT 初始化的 GRPO 组形成对比。

c. SFT-GRPO-R2 组

该组在 CoT-SFT merged 模型基础上进行 GRPO 训练，奖励函数使用 R2，即在正确性奖励之外加入格式奖励。该实验主要用于分析格式奖励是否能够提升模型输出的规范性，例如是否更稳定地按照要求给出 Final Answer。

d. SFT-GRPO-R3 组

该组同样以 CoT-SFT merged 模型作为初始化模型，奖励函数使用 R3，即在正确性奖励和格式奖励的基础上进一步加入长度惩罚。该实验用于分析长度惩罚是否能够减少冗余推理内容，降低模型过度推理的风险。

通过上述实验设计，本文可以系统比较不同初始化方式和不同奖励约束对模型表现的影响。具体而言，本文将从准确率、格式成功率、答案抽取率、平均输出长度和过度推理率等多个角度进行分析，从而更全面地考察 GRPO 后训练对小型大语言模型数学推理行为的作用机制。

2.8 评价指标

为了避免仅使用准确率评价模型，本文设计了多维度评价指标，从答案正确性、格式规范性、答案可抽取性以及输出冗长程度等方面综合分析模型表现。

首先，在准确率方面，本文同时使用 `accuracy_strict` 和 `accuracy_lenient` 两类指标。`accuracy_strict` 表示严格答案抽取条件下的准确率，要求模型输出中包含规范的 Final Answer 字段，并且答案能够被成功解析。因此，该指标不仅反映模型答案是否正确，也间接反映模型是否遵循规定输出格式，是本文的主要评价指标。相比之下，`accuracy_lenient` 采用更宽松的数值抽取方式，即使模型没有严格按照格式输出，也会从回答中兜底提取最后可能的数值作为答案。该指标主要用于估计模型真实计算能力的上限，避免因格式错误而完全否定模型的推理能力。

其次，在格式与自动评测可靠性方面，本文使用 `format_success_rate` 和 `answer_extraction_rate_strict` 进行衡量。其中，`format_success_rate` 用于统计模型回答是否包含规范的 Final Answer 格式，主要反映模型的指令跟随能力和格式稳定性；`answer_extraction_rate_strict` 则衡量严格规则下答案被成功抽取的比例，用于分析奖励函数设计和自动评测流程是否可靠。

最后，为了分析模型在后训练过程中是否出现推理冗长的问题，本文进一步统计 `avg_response_length_words`、`overthinking_rate` 和 `length_accuracy_correlation`。其中，

avg_response_length_words 表示模型平均输出词数，用于观察不同训练设置是否会导致回答长度增加；
overthinking_rate 表示超过设定长度或出现明显过度推理现象的比例，用于评估模型是否存在冗长推理风险；
length_accuracy_correlation 表示输出长度与答案正确性之间的相关系数，用于判断更长的推理过程是否真正带来了更高的准确率。

3. 实验与结果分析

3.1 实验平台与实验内容

实验在单卡 A800 80GB GPU 环境中完成，训练框架基于 PyTorch、Transformers、TRL、PEFT 和 datasets，其中 GRPO 训练主要依赖 TRL，LoRA 微调主要依赖 PEFT^{[9][10]}。为保证结果可复现，所有数据划分均固定随机种子 seed=42，最终评测统一使用完整 GSM8K test split，共 1319 道题^[11]。评测时最大生成长度设置为 512，以避免合理推理过程被过早截断。

实验内容包括六组：E1 Base，直接评测原始 Qwen2.5-1.5B-Instruct；E2 CoT-SFT，使用蒸馏 CoT 数据进行 LoRA 监督微调；E3 GRPO，从 Base 模型直接进行正确性奖励强化学习；E4-R1、E4-R2 和 E5-R3，则分别在 SFT 合并模型基础上进行三种奖励函数的 GRPO 消融。

表 2 实验组别设计

组别	方法	初始化	训练信号
E1	Base	Qwen2.5-1.5B-Instruct	无
E2	CoT-SFT	Base	蒸馏 CoT 标签
E3	GRPO	Base	正确性奖励
E4-R1	SFT-GRPO-R1	CoT-SFT	正确性奖励
E4-R2	SFT-GRPO-R2	CoT-SFT	正确性 + 格式奖励
E5-R3	SFT-GRPO-R3	CoT-SFT	正确性 + 格式 - 长度惩罚

3.2 主实验结果

完整测试集结果如表 3 所示。可以看到，Base 模型已经具备一定数学推理能力，但严格准确率和宽松准确率之间存在明显差距，说明答案格式不稳定是原始模型的重要问题。CoT-SFT 之后，严格准确率和格式成功率大幅提升；GRPO 单独训练取得最高准确率，但输出长度和过度推理率也同步上升；SFT-GRPO 三组在格式稳定性方面保持较高水平，但准确率没有超过单独 GRPO。

表 3 完整 GSM8K test 上的主实验结果

组别	Strict Acc	Lenient Acc	Format	Avg Words	Overthink
E1	42.38%	48.67%	53.22%	139.82	0.00%
E2	63.08%	63.15%	99.17%	107.86	0.68%
E3	69.98%	70.43%	97.50%	157.94	4.25%
E4-R1	64.06%	64.06%	99.47%	107.81	0.61%
E4-R2	64.14%	64.22%	99.32%	108.06	0.76%
E5-R3	64.75%	64.75%	99.24%	109.39	0.68%




图 3 各方法在 GSM8K test 上的严格与宽松准确率对比

为综合对比各方法，图 4 以雷达图形式展示六种方法在严格准确率、格式成功率、答案抽取率、输出简洁性与低过度推理五个维度上的表现（各维度按方法间最小最大值归一化）。可以看到，GRPO 在准确率维度领先但在简洁性与低过度推理维度较弱，SFT-GRPO 系列则在格式、抽取与简洁性维度更均衡。




图 4 各方法多维指标综合对比（雷达图，各维度已归一化）

3.3 CoT-SFT 对格式规范性和准确率的影响

CoT-SFT 的效果非常显著。Base 的 strict accuracy 为 42.38%，lenient accuracy 为 48.67%，二者相差 6.29 个百分点。这说明一部分题目中模型已经得到了正确数值，但没有按指定格式输出，导致严格评测失败。CoT-SFT 后，strict accuracy 提升到 63.08%，相对 Base 提升 20.70 个百分点；lenient accuracy 提升到 63.15%，与 strict accuracy 几乎一致。该现象说明 SFT 不仅提升了模型求解能力，更重要的是消除了大量格式不规范造成的评测损失。

从格式指标看，Base 的 format_success_rate 仅为 53.22%，而 CoT-SFT 提升到 99.17%；strict answer extraction rate 也从 56.25% 提升到 99.09%。这说明通过 GSM8K 风格 CoT 蒸馏，模型几乎稳定学会了在回答末尾输出 Final Answer 格式。对于后续 GRPO 来说，这一点尤其重要，因为奖励函数依赖严格答案抽取。如果模型无法被抽取器稳定识别，即使其真实答案正确，训练时也会得到错误奖励，导致强化学习信号噪声增大。

值得注意的是，CoT-SFT 的平均输出长度为 107.86 words，低于 Base 的 139.82 words。这说明经过数据清洗和 strip_think 处理后，SFT 并没有简单诱导模型生成更长文本，而是使模型输出更简洁、更规范。这与早期直接使用完整长 CoT 的失败现象形成对比，也说明 SFT 数据质量和目标格式设计比单纯增加推理长度更重要。




图 5 不同方法在 GSM8K test 上的格式成功率与严格答案抽取成功率

3.4 GRPO 对准确率与输出行为的影响

单独 GRPO 组取得了全部实验中的最高准确率：strict accuracy 为 69.98%，lenient accuracy 为 70.43%。与 Base 相比，严格准确率提升 27.60 个百分点；与 CoT-SFT 相比，也高出 6.90 个百分点。这说明即使没有 SFT 初始化，基于规则正确性奖励的 GRPO 也能显著增强小模型在 GSM8K 上的数学推理表现。

但 GRPO 的提升并非没有代价。该组平均输出长度达到 157.94 words，是所有方法中最高的；overthinking_rate 也达到 4.25%，明显高于 CoT-SFT 和 SFT-GRPO 系列。也就是说，GRPO 在提高答案正确率的同时，推动模型生成更长的推理过程。这可能是因为正确性奖励只在最终答案层面给出信号，模型为了提高命中奖励的概率，会倾向于输出更完整、更保守或更长的步骤。

从格式角度看，GRPO 组的 format_success_rate 为 97.50%，虽然低于 SFT 系列的 99% 左右，但仍显著高于 Base。这表明在训练 prompt 和奖励机制的共同作用下，即使只使用正确性奖励，模型也能在一定程度上学到规范答案格式。然而，与 CoT-SFT 相比，GRPO 的格式稳定性略低，说明监督信号在格式学习上更直接，而强化学习更侧重最终奖励优化。




图 6 不同方法在 GSM8K test 上的平均输出长度与过度推理率

3.5 SFT-GRPO 与奖励函数消融分析

SFT-GRPO 三组的准确率均略高于 CoT-SFT，但低于单独 GRPO。其中 R1、R2、R3 的 strict accuracy 分别为 64.06%、64.14% 和 64.75%。这说明在 SFT 初始化基础上继续进行 GRPO 可以带来小幅提升，但提升幅度有限。R3 是 SFT-GRPO 系列中表现最好的方案，比 R1 高 0.69 个百分点，比 CoT-SFT 高 1.67 个百分点。

从格式指标看，SFT-GRPO 三组均保持了非常高的格式成功率：R1 为 99.47%，R2 为 99.32%，R3 为 99.24%。这说明 SFT 学到的格式能力在后续 GRPO 中基本被保留下来。与单独 GRPO 相比，SFT-GRPO 的输出更稳定、更短，平均长度约为 108 到 109 words，明显低于 GRPO 的 157.94 words。

R2 在 R1 基础上加入格式奖励，但准确率只从 64.06% 提升到 64.14%，格式成功率反而略低。这并不说明格式奖励无效，而是因为 SFT 初始化后的格式成功率已经接近饱和，额外格式奖励能提供的增益很小。R3 加入长度惩罚后取得组内最高准确率，但平均长度并未明显低于 R1。这说明简单长度惩罚在本实验中主要起到轻微正则化作用，不能完全解决输出长度控制问题。

一个值得讨论的现象是，SFT-GRPO 没有超过单独 GRPO。可能原因包括：第一，SFT 已经将模型行为压到较规范、较短的输出模式，使后续 RL 探索空间变小；第二，GRPO 单独训练虽然输出更长，但这种更大探索可能带来更高答案命中率；第三，SFT-GRPO 的训练步数、奖励权重和采样数量可能仍未达到最优。因此，本文不能简单得出“SFT 初始化一定优于直接 GRPO”的

结论，而应认为二者体现了不同的行为倾向：SFT 更稳，GRPO 更激进。

表 4 奖励函数消融结果

方法	Strict Acc	Format	Avg Words
SFT-GRPO-R1	64.06%	99.47%	107.81
SFT-GRPO-R2	64.14%	99.32%	108.06
SFT-GRPO-R3	64.75%	99.24%	109.39

从表 4 可以看出，三种 SFT-GRPO 方法的格式成功率均保持在 99% 左右，说明在 CoT-SFT 初始化基础上，模型已经具备较强的格式遵循能力。相比 R1，加入格式奖励后的 R2 准确率仅有小幅提升，说明格式约束对已经经过 SFT 规范化的模型作用有限。R3 在加入长度惩罚后取得组内最高严格准确率 64.75%，但平均输出长度并未明显下降，反而略高于 R1 和 R2。这表明简单的长度惩罚虽然没有显著压缩输出长度，但在一定程度上改善了模型的整体输出行为。总体来看，SFT-GRPO 系列的主要优势在于格式稳定，而不同奖励函数之间的准确率差异相对较小。

3.6 训练过程分析

为分析 GRPO 的训练动态，本文记录了四个强化学习实验组的奖励、损失、KL 散度与生成长度随训练步数的变化。需要特别说明的是，不同奖励配置的绝对奖励不可直接比较：R2、R3 的奖励函数额外包含格式奖励项，因此其奖励曲线整体高于仅含正确性奖励的 R1；真正处于同一量纲、可直接比较的是从 Base 直接训练的 GRPO 与 SFT 初始化的 R1，二者奖励均稳定在约 0.7 附近。

如图 7 (a) 所示，各组奖励曲线在训练过程中噪声较大且整体趋于平稳，并未出现持续显著上升。这表明在单卡、200 步的训练预算下，GRPO 在小模型上收敛较快、可提升空间有限，与最终评测中 SFT-GRPO 相对 CoT-SFT 仅有约 1 个百分点提升的结果一致。整个训练过程未出现奖励崩塌、KL 散度发散或生成长度失控等异常，说明本文的奖励设计与训练配置是稳定的。




图 7 GRPO 训练过程：(a) 训练奖励；(b) 训练损失；(c) KL 散度（淡线为原始值，粗线为 EMA 平滑）

此外，训练损失与 KL 散度见图 7 (b) (c)：损失整体下降后趋于小幅震荡，KL 散度始终维持在较小范围，说明策略更新幅度受控、训练过程稳定，未出现策略发散。

3.7 输出长度与正确率关系分析

本实验特别关注“输出更长是否意味着推理更强”这一问题。实验结果显示，所有方法的 `length_accuracy_correlation` 均为负值：Base 为 -0.447，CoT-SFT 为 -0.218，GRPO 为 -0.329，SFT-GRPO-R3 为 -0.211。这表明在 GSM8K 测试集中，输出越长并不必然越正确，甚至在统计上呈现弱到中等程度的负相关。

这一现象有两层含义。第一，对于简单题目，正确模型往往可以用较短步骤完成推理，过长回答反而可能意味着模型不确定或反复修正。第二，对于错误题目，模型可能在错误假设上展开更多步骤，导致文本变长但答案仍然错误。因此，推理长度不能直接作为推理能力指标。真正有效的后训练方法应该同时提升答案正确率、格式稳定性和推理效率，而不是单纯延长回答。

GRPO 组的结果尤其说明了这种张力：它取得最高准确率，但也产生最长输出和最高过度推理率。SFT-GRPO 系列则牺牲一部分最高准确率，换来了更短、更稳定的输出。因此，如果面向实际应用，最佳方法不一定是准确率最高的 GRPO，也可能是准确率略低但格式稳定、输出更短的 SFT-GRPO-R3。




图 8 输出长度分析：(a) 分桶严格准确率；(b) 平均长度与严格准确率；(c) 各方法输出长度分布

为更直观地展示准确率与输出长度的权衡，图 8 (b) 以散点形式给出各方法的平均输出长度与严格准确率。GRPO 位于高准确率、高长度的右上区域，CoT-SFT 与 SFT-GRPO 系列则以更短的输出取得相近准确率，

Base 位于左下。这进一步印证了更高准确率往往以更长输出为代价，而 SFT 初始化的方法在效率上更优。

3.8 典型错误类型分析

为了进一步解释不同后训练方法对模型行为的影响，本文对典型错误案例进行人工归因分析。根据模型输出表现，错误大致可以分为格式错误、条件理解错误、数值尺度错误和过度推理错误四类。

a. 格式错误

格式错误是指模型的计算过程或最终数值可能是正确的，但没有按照规定形式输出 Final Answer，导致 strict 评测失败。这类错误在 Base 模型中较为常见。例如，模型最后写成 “Therefore, the answer is 18 dollars”，宽松抽取可以得到正确答案 18，但由于没有出现规范的 Final Answer 标记，严格抽取失败。该类错误说明，原始模型并非完全没有求解能力，而是存在指令遵循和答案收束格式不稳定的问题。CoT-SFT 后格式成功率显著提高，说明监督蒸馏对这类错误具有明显改善作用。

b. 条件理解错误

条件理解错误是指模型误读题干中的比较关系、数量关系或计算基准。例如，在房屋翻修题中，题目中的“价值增加 150%”应基于原房价计算，而模型可能错误地基于“购房价格加维修投入”的总成本计算，从而得到偏大的利润结果。这类错误反映出模型在自然语言条件建模方面仍然存在不足。即使模型能够进行算术计算，如果对题目条件的理解出现偏差，最终答案仍会错误。

c. 数值尺度错误

数值尺度错误主要表现为金额、单位、千位分隔或数量级处理不稳定。模型有时能够得到正确的计算方向，但在最终输出中丢失数量级，例如将 145,000 写成 145；或者在答案中保留货币符号、逗号和解释性文字，影响答案抽取器解析。这类错误在各组模型中均可能出现，说明数学推理任务不仅要求模型完成计算，还要求模型以统一、可解析的数值形式输出最终答案。

d. 过度推理错误

过度推理错误是指模型在已经得到正确中间结果后继续展开不必要的检查、假设或解释，并在后续推理中引入新的错误。这类错误在 GRPO 组中更值得关注，因为 GRPO 组平均输出长度最高，过度推理率也相对更高。该现象说明，强化学习后训练可能会鼓励模型生成

更完整的推理过程，但如果缺乏有效的停止约束，模型可能在正确答案附近继续推理，反而增加出错风险。

为定量刻画上述错误类型的分布，本文对全部六组方法在测试集上的严格错误样本进行自动归因，结果如图 9 所示。最显著的现象是：原始模型的 760 个错误样本中，约 81%（格式错误 536 个、抽取失败但答案实际正确 83 个）属于格式或抽取问题，真正的计算或推理错误仅占约 19%。这意味着 Base 的低准确率在很大程度上是“不会规范作答”造成的假象，其潜在推理能力被严重低估。经过后训练后，格式类错误几乎被消除，严格错误总数由 760 降至 487（CoT-SFT），其中约 98% 为真实推理错误。需要强调的是，这里“真实推理错误”占比的大幅上升属于错误构成的变化，而非推理能力下降：Base 的真实推理错误大量被“缺 Final Answer”的格式失败所掩盖（这类样本无法判定底层推理对错，统计中被全部计入格式错误），因此其 141 这一计数被严重低估。若以宽松口径统一衡量，真正答错的题目数量实际由约 677（Base）下降至 476（CoT-SFT），表明后训练在规范输出格式的同时，真实推理正确率也确实得到提升。该结果定量支持了本文的核心论点：小模型后训练的首要收益是输出格式的规范化，其次才是推理能力的提升。




图 9 各方法错误类型构成（占严格错误的比例）

3.9 结果讨论

综合来看，本实验可以得出结论：不同后训练方法改善的是模型行为的不同方面。CoT-SFT 更像是“行为格式校准器”，它通过监督学习让模型稳定形成题目分析、步骤计算和 Final Answer 收束模式，因此严格准确率显著提高。GRPO 更像是“结果导向优化器”，它通

过正确性奖励推动模型探索能够获得高分的回答方式，因此最终准确率最高，但输出长度也更容易膨胀。

这一结果对大语言模型推理增强具有启示意义。对于参数规模较小的大语言模型，数据分布对齐和答案格式设计非常关键。若蒸馏数据来自竞赛数学或答案类型复杂的数据集，即使 CoT 很长，也可能与 GSM8K 任务不匹配。本文最终改用 GSM8K 风格蒸馏数据，并去除过长 think 部分，才使 SFT 稳定提升。这说明高质量蒸馏不是简单堆叠长推理，而是要保证题目分布、解题风格和最终评测目标一致。

此外，奖励函数设计需要在准确率、格式和长度之间权衡。只用正确性奖励可以取得最高分，但可能增加输出长度；加入格式奖励在 SFT 已经接近格式饱和时增益有限；加入长度惩罚能够带来轻微准确率提升，但对平均长度没有显著压缩。未来可以尝试更细粒度的过程奖励、分阶段奖励或基于错误类型的自适应奖励，而不是只在最终答案层面给出稀疏反馈。

3.10 数据源选择与预实验反思

此部分总结本实验在预实验阶段中的失败与经验：第一版 CoT-SFT 不升反降。在完整 GSM8K test 上，第一版 SFT 的严格准确率仅 3.6%（1319 题中仅 47 题正确），不仅没有超过 Base，反而远低于 Base 的 42.4%；格式成功率仅约 4.3%，宽松准确率也只有 13.3%。检查模型输出发现，回答大多以 \boxed{...} 形式给出，并在 max_new_tokens 处被截断，几乎从不输出规定的 "Final Answer:" 标记。

经逐项排查，这次崩溃是多重原因叠加导致的。其一，训练与评测的输入分布不一致，这是预实验失败的主要原因：第一版 SFT 采用裸文本拼接训练（无 ChatML 对话模板、无 system 段），而评测使用 tokenizer.apply_chat_template 渲染为 ChatML 格式，于是 LoRA 学到的输入模式在评测时根本不会出现。其二，训练时未对回答区做损失掩码，监督信号被大量浪费在复现 prompt 前缀上。其三是序列截断：蒸馏目标过长（token 数中位约 918、p90 约 1888、最长 3657），而 max_seq_length 仅 1024，导致 38% 以上样本结尾的 "Final Answer:" 被直接截掉，模型从未在完整目标上学会收尾。此外，早期还曾尝试 OpenR1-Math 这类竞赛、

证明、选择题数据^[13]，其答案常非单个数字，与 GSM8K 的题目分布和答案抽取协议严重错配，进一步放大了上述问题。

针对上述原因，本文做了四项关键调整：第一，训练输入改用与评测逐字节一致的 ChatML 模板渲染，消除训练/评测分布差异；第二，引入 completion-only 损失掩码，只在回答上计算 loss；第三，采用 strip_think 策略，仅保留 </think> 之后的简洁正式解作为 SFT 目标，并将 max_seq_length 提升到 2048，确保 "Final Answer:" 不被截断；第四，数据源改用与 GSM8K 风格一致、答案为单一数值的 camel-ai/gsm8k_distilled。

修复后，第二版 SFT 完全恢复正常：严格准确率由 3.6% 提升到 63.1%，宽松准确率由 13.3% 提升到 63.2%，格式成功率由约 4.3% 提升到 99.2%；尤其严格与宽松准确率几乎相等，说明答案格式已经稳定、不再依赖宽松兜底。这一经验随后被推广到 GRPO 阶段——本文发现 GRPO 的 rollout prompt 同样存在“未套用对话模板”的隐患（数据准备脚本将 prompt 写成了纯字符串），遂在训练前把 prompt 统一重建为消息列表，保证强化学习采样与评测的输入模板逐字节一致。

这次失败—定位—修复的过程对本实验有着重要的意义：对小型大语言模型而言，后训练的成败往往不在于方法是否“高级”，而在于训练与评测协议是否对齐、数据分布与目标任务是否一致、关键监督信号（如 Final Answer）是否被完整保留。因此，本文并非机械套用 DeepSeek-R1 风格的长思维链流程，而是在有限容量与单卡环境下，围绕 GSM8K 任务特点做了上述针对性调整。

3.11 学习体会与实验心得

本实验的过程，对本人而言是一次从复现方法到理解机制的学习过程。最初本实验照搬 DeepSeek-R1 式的长思维链强化学习范式，但预实验很快暴露问题：竞赛风格的长 CoT 数据与 GSM8K 的题目分布、答案格式严重错配，模型学到了不适合本任务的书写风格。这让本人体会到，后训练并非方法越高级越好，数据与目标任务的一致性往往比模型规模或方法新颖度更关键。

在方法选型上，本实验之所以采用 SFT→GRPO 的两段式，是基于对二者作用边界的理解：SFT 擅长快速注入“规范输出格式”与“分步书写范式”，但只能模仿、难以超越教师；GRPO 则以最终答案正确性为信号，允许模型在自我采样中探索更优解。至于强化学习算法，相比需要额外价值网络的 PPO、以及依赖成对偏好数据的 DPO，GRPO 以“组内相对”的方式同时回避了价值网络的显存开销与人工偏好标注，在单卡小模型场景下最为务实，故成为本实验的选择。

最令人印象深刻的一点是“奖励即目标”：当奖励只奖励最终答案正确时，GRPO 组确实取得了最高准确率，却也产生了最长、最易过度推理的输出——模型忠实地优化了被给定的信号，而非本实验真正想要的“既正确又简洁”。这也正是本实验追加格式奖励与长度惩罚做消融的原因。尽管长度惩罚的实际效果有限，但这一系列结果让本人真切体会到：在强化学习后训练中，如何设计奖励，几乎等价于在定义“什么才是更好的回答”。

4. 结论

本文围绕小型大语言模型数学推理能力增强问题，构建了基于 CoT-SFT 与 GRPO 的完整实验流程，并在完整 GSM8K test split 上进行了系统对比。实验表明，原始 Qwen2.5-1.5B-Instruct 已具备一定数学推理能力，但存在格式不稳定和严格答案抽取失败的问题。CoT-SFT 能显著提升格式规范性和严格准确率，使 `format_success_rate` 从 53.22% 提升到 99.17%，`strict accuracy` 从 42.38% 提升到 63.08%。这说明对小模型而言，监督蒸馏不仅是学习推理步骤，更是学习可评测、可奖励的输出协议。

GRPO 单独训练取得最高准确率，`strict accuracy` 达到 69.98%，证明基于规则正确性奖励的强化学习可以有效提升小模型数学推理表现。但该方法也带来平均输出长度上升和过度推理率增加，说明单纯追求最终答案奖励可能诱导模型生成更长推理。SFT-GRPO 系列在格式稳定性上表现最好，但准确率未超过单独 GRPO，说明 SFT 初始化并不必然带来更强 RL 最终性能，它可能降低探索空间，同时提高输出稳定性。

本文的一个重要发现是，输出长度与正确率在所有实验组中均呈负相关。由此可以看出，长思维链不能直接等同于强推理能力。合理的推理增强应在正确性、格式稳定性和生成效率之间取得平衡。对于实际应用，CoT-SFT 或 SFT-GRPO-R3 这类输出更稳定、格式更可靠的方法可能比单纯准确率最高的 GRPO 更适合部署；而对于追求 benchmark 分数的研究设置，直接 GRPO 具有更高上限。

本实验仍存在一些不足。首先，实验只使用单一基座模型和单一随机种子，结果可能存在方差；其次，GRPO 训练步数和奖励权重没有进行大规模网格搜索，SFT-GRPO 未超过 GRPO 的原因仍需进一步验证；再次，错误类型分析主要依赖规则统计和少量人工观察，尚未形成自动化细粒度错误诊断系统。未来工作可以扩展到不同规模的 Qwen 或 LLaMA 系列模型，引入多 seed 稳健性分析，尝试过程奖励、难度分层训练和自适应长度惩罚，并在 GSM8K 之外的 MATH、SVAMP 或 MultiArith 等数据集上验证泛化能力。

5. 参考文献

- [1] Wei J., Wang X., Schuurmans D., et al. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. NeurIPS, 2022.
- [2] Cobbe K., Kosaraju V., Bavarian M., et al. Training Verifiers to Solve Math Word Problems. arXiv:2110.14168, 2021.
- [3] Hu E. J., Shen Y., Wallis P., et al. LoRA: Low-Rank Adaptation of Large Language Models. ICLR, 2022.
- [4] Schulman J., Wolski F., Dhariwal P., et al. Proximal Policy Optimization Algorithms. arXiv:1707.06347, 2017.
- [5] Shao Z., Wang P., Zhu Q., et al. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models. arXiv:2402.03300, 2024.
- [6] Guo D., Yang D., Zhang H., et al. DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning. arXiv:2501.12948, 2025.
- [7] Yang A., Yang B., Zhang B., et al. Qwen2.5 Technical Report. arXiv:2412.15115, 2024.

- [8] Yang A., Gao B., Yu B., et al. Qwen2.5-Math Technical Report: Toward Mathematical Expert Model via Self-Improvement. arXiv:2409.12122, 2024.
- [9] Hugging Face TRL Documentation. GRPOTrainer and reinforcement learning post-training documentation.
- [10] Hugging Face PEFT Documentation. LoRA and parameter-efficient fine-tuning documentation.
- [11] OpenAI. GSM8K dataset: grade school math word problems benchmark.
- [12] CAMEL-AI. gsm8k_distilled: GSM8K distilled chain-of-thought dataset. Hugging Face Dataset.
- [13] Open-R1. OpenR1-Math-220k dataset. Hugging Face Dataset.